E12 · Plan de evolución

Frecuencias inteligentes SOBUSA: integración, escalabilidad, costos y riesgos

Roger Daza Matteo Del Sole Rafael Romero
Universidad del Norte · Reto Extreme Technologies – SOBUSA

29 de octubre de 2026

1. Punto de partida

El prototipo funciona de punta a punta con tres rutas (SILENCIO, CRA 54 y CL 72) y datos hasta diciembre de 2025:

- Lee la base del operador en solo lectura.
- Pronostica la demanda a 30, 60 y 120 minutos, con un error de 10–11 % frente a 14,9 % de la referencia.
- Recomienda la frecuencia con una función objetivo.
- Genera y agrupa alertas.
- Monitorea su propio desempeño y reentrena de forma controlada.

Corre en Docker Compose con 322 pruebas automáticas y un análisis de SonarQube sin hallazgos. Lo que falta para operar no es software sino tres cosas:

- validar los parámetros operativos con SOBUSA;
- probar la herramienta con los despachadores;
- llevarla a la infraestructura del operador.

Este plan ordena esos pasos.

2. Hoja de ruta

3. Integración

- **Fuente de datos.** Pasar de la base operacional a una réplica de lectura. El código ya usa transacciones de solo lectura, timeout y consultas por rango con índices existentes (E07).
  - Si el operador completa los consolidados `timbradas_*`, basta con cambiar las consultas de `ingesta/consultas.py`.
  - Para relecturas de periodos corregidos, la recarga del histórico es idempotente. Falta exponer la recarga por rango.
  - Índice sugerido para el DBA: (`idprogramacion`, `fecha`) en `conteo_pasajeros_destino`, previa revisión con `EXPLAIN`.

Fase	Duración	Qué se hace	Criterio para pasar a la siguiente
0. Validación	2 semanas	Capacidad real por tipología de bus, headway máximo por ruta y franja, flota disponible por ruta, pesos de la función objetivo y umbrales de alerta. Credenciales de correo y WhatsApp. Despliegue en el ambiente de pruebas de Extreme Technologies contra una réplica de lectura.	Parámetros marcados como validados en `operational_parameter`. Ciclo horario 7 días seguidos sin intervención manual.
1. Piloto consultivo	4 semanas	CL 72 y SILENCIO, las rutas con mayor diferencia entre lo operado y lo recomendado. Los despachadores usan la pantalla *Hoy* y gestionan alertas agrupadas. La decisión sigue siendo humana; se registra si se siguió la recomendación.	Indicadores de la Sección 7 iguales o mejores que las mismas semanas del año anterior. Alertas descartadas bajo 30 %.
2. Producción	6–8 semanas	Las tres rutas. Ingreso con las cuentas del operador (SSO), respaldo diario, monitoreo con las herramientas del operador, notificaciones reales por turno, servidor de base separado de la aplicación.	Disponibilidad del ciclo $\geq$ 99 % en un mes; cero incidentes sobre la base operacional.
3. Extensión	continua	Más rutas por grupos. Mejoras del modelo: sentido de la ruta, demanda por segmento, flota compartida entre rutas y planificación del día siguiente.	Cada ruta nueva supera la línea base en su validación temporal antes de activarse.

- **Identidad.** Hoy el acceso es con claves por rol (lector, operador, administrador). En producción conviene conectar el ingreso al directorio del operador (OpenID Connect) para que la bitácora de alertas, activaciones y parámetros registre personas, no claves.
- **Notificaciones.** Los adaptadores de correo (SMTP con TLS) y WhatsApp Cloud API están implementados. Falta la cuenta institucional, una plantilla aprobada por Meta y la lista de destinatarios por ruta y turno.
- **Sistema de despacho.** La API `/api/v1` ya permite que otro sistema consulte recomendaciones y alertas. Una evolución natural es notificar cambios por *webhook* en lugar de consultar.
- **Observabilidad.** El prototipo expone métricas Prometheus y trazas OpenTelemetry; se conectan a la plataforma que use el operador. Alarmas recomendadas:
  - ciclo fallido o interrumpido;
  - latencia de datos mayor a 2 periodos;
  - deriva o degradación del modelo.

Componente	Hoy (3 rutas)	Con 50 rutas
Histórico de demanda	240.000 franjas en 3 años (unas 27.000 por ruta y año)	Unas 1,3 millones por año: sin cambios para PostgreSQL
Observaciones por segmento	1,18 millones de filas	Crece con viajes × segmentos: particionar por mes (§8.1) al superar unos 10 millones
Ingesta	808.345 registros en 149 s, pico de 964 MB	Procesar por ruta y fecha (RNF-005), en paralelo
Entrenamiento completo	37 min (3 horizontes, 15 intentos de Optuna) en un equipo de desarrollo	Horas: reentrenar sin búsqueda de hiperparámetros (ya lo hace el campeón/retador), más núcleos o modelos por grupo de rutas
Ciclo incremental	Un proceso, un ciclo a la vez	Un trabajo por ruta con exclusión por ruta en lugar de global
API	Un proceso; consultas paginadas con p95 de 146 ms	Varias réplicas tras un balanceador, con la reanudación de ciclos solo en el programador (`CICLO_REANUDAR=desactivada`)
Predicción interactiva	4,5 s por cálculo	La pantalla *Hoy* lee resultados ya calculados por el ciclo; el cálculo interactivo queda para consultas puntuales

4. Escalabilidad

5. Costos

Licencias: cero. Todo el sistema usa software libre: PostgreSQL, PostGIS, Python, FastAPI, LightGBM, SonarQube Community, Prometheus y Jaeger. El único costo variable externo es la mensajería de WhatsApp Business, que Meta cobra por conversación; se cotiza según el volumen de alertas críticas. Con los umbrales actuales son unas 13 alertas críticas al día entre las tres rutas, y se reducen al validar la capacidad.

Infraestructura.

- **Piloto.** Un servidor de 4 vCPU, 16 GB de RAM y 100 GB de disco con Docker basta. El pico de memoria medido es de 964 MB en la ingesta y la imagen pesa 1,9 GB.
- **Producción.** Dos servidores (aplicación y base de datos), respaldo diario de la base y de `modelos/`, y el monitoreo del operador.

El valor en pesos depende de si se usa infraestructura propia del operador o un proveedor de nube. Se debe cotizar con estas cifras.

Esfuerzo estimado.

Fase	Equipo	Esfuerzo
0. Validación	1 analista + contraparte operativa de SOBUSA	unas 3 personas-semana
1. Piloto	1 ingeniero + acompañamiento a despachadores	unas 5 personas-semana
2. Producción	2 ingenieros	unas 14 personas-semana
3. Extensión	1 ingeniero a medio tiempo	continuo

Beneficio por verificar en el piloto. Al recalcular con la función objetivo las 748 horas-ruta del 1 al 14 de diciembre de 2025, la recomendación usa 608 vehículo-horas menos que lo operado en esas dos semanas, unas 43 por día entre las tres rutas.

- El saldo es neto: CL 72 necesitaría más buses y SILENCIO menos.
- Depende de parámetros todavía sin validar: capacidad, headway máximo y pesos.

El ahorro en pesos es esa cifra por el costo de una vehículo-hora, dato que debe aportar SOBUSA. El piloto existe para confirmarla o corregirla.

6. Riesgos y mitigaciones

Riesgo	**Mitigación**
Parámetros operativos sin validar	Fase 0. Son parámetros versionados en la base: se corrigen sin desarrollo y queda la versión anterior.
Baja adopción por los despachadores	Piloto consultivo; recomendaciones en lenguaje operativo con su razón; pantalla *Hoy*; registro de si se siguió la recomendación.
Alertas excesivas	Agrupación por ruta, código y día con gestión en lote; medición del porcentaje de descartadas por regla; recalibración con la capacidad validada.
Mala calidad de los datos de sensores	Reglas de calidad CAL-xxx por lote, días sin lecturas tratados como faltantes, ALT-008 y ALT-009.
Deriva o degradación del modelo	Monitoreo de deriva, error y cobertura en cada ciclo; reentrenamiento campeón/retador; reversión a la versión anterior en un clic.
Carga sobre la base operacional	Réplica de lectura, consultas por rango indexadas, transacciones de solo lectura con timeout, índices solo con aprobación del DBA.
Recomendación inviable	Restricciones duras de flota, headway y capacidad; la recomendación se marca *no viable* con el motivo.
Caídas y reinicios	Trabajos con latido, reanudación automática y reintentos, verificados con una caída real de la API.
Exposición de datos	Mínimo privilegio en las dos bases, sin datos personales de conductores, claves con huella, secretos fuera del repositorio.
Dependencia del equipo actual	Manuales técnico, de usuario y de despliegue; 322 pruebas; integración continua con SonarQube; explicación de cada archivo en `comentarios_codigo.pdf`.
Compatibilidad de librerías	Versiones fijadas en `requirements.txt`; la instrumentación de trazas sobre SQLAlchemy 2.1 está cubierta por pruebas.

7. Indicadores del piloto

Todos se calculan con datos que el sistema ya guarda:

- espera media estimada (la mitad del headway operado) y ocupación p90 en el tramo más cargado;
- vehículo-horas operadas por día y ruta;
- porcentaje de horas con despachos fallidos (ALT-006);
- error del pronóstico (WAPE) y cobertura del intervalo;
- porcentaje de alertas descartadas;
- porcentaje de horas en que se siguió la recomendación.

8. Decisiones que requiere SOBUSA

1. Capacidad por tipología de bus, headway máximo por ruta y franja, y flota disponible por ruta.
2. Valor relativo entre costo de operación, espera de los pasajeros y sobreocupación (pesos de la función objetivo), y costo de una vehículo-hora.
3. Rutas y semanas del piloto, y responsables de operación que lo acompañan.
4. Infraestructura (propia o en la nube), réplica de lectura y directorio para el ingreso.
5. Cuentas de correo y WhatsApp para las notificaciones, y destinatarios por turno.