# E12 · Plan de evolución

Frecuencias inteligentes SOBUSA: integración, escalabilidad, costos y riesgos

Roger Daza  Matteo Del Sole  Rafael Romero
Universidad del Norte · Reto Extreme Technologies – SOBUSA

29 de octubre de 2026

## 1. Punto de partida

El prototipo funciona de punta a punta con tres rutas (SILENCIO, CRA 54 y CL 72) y datos hasta diciembre de 2025:

- Lee la base del operador en solo lectura.
- Pronostica la demanda a 30, 60 y 120 minutos, con un error de 10–11 % frente a 14,9 % de la referencia.
- Recomienda la frecuencia con una función objetivo.
- Genera y agrupa alertas.
- Monitorea su propio desempeño y reentrena de forma controlada.

Corre en Docker Compose con 299 pruebas automáticas y un análisis de SonarQube sin hallazgos. Lo que falta para operar no es software sino tres cosas:

- validar los parámetros operativos con SOBUSA;
- probar la herramienta con los despachadores;
- llevarla a la infraestructura del operador.

Este plan ordena esos pasos.

## 2. Hoja de ruta

## 3. Integración

- **Fuente de datos.** Pasar de la base operacional a una réplica de lectura. El código ya usa transacciones de solo lectura, timeout y consultas por rango con índices existentes (E07).
  - Si el operador completa los consolidados `timbradas_*`, basta con cambiar las consultas de `ingesta/consultas.py`.
  - Para relecturas de periodos corregidos, la recarga del histórico es idempotente. Falta exponer la recarga por rango.
  - Índice sugerido para el DBA: (`idprogramacion`, `fecha`) en `conteo_pasajeros_destino`, previa revisión con `EXPLAIN`.

| Fase | Duración | Qué se hace | Criterio para pasar a la siguiente |
|---|---|---|---|
| 0. Validación | 2 semanas | Capacidad real por tipología de bus, headway máximo por ruta y franja, flota disponible por ruta, pesos de la función objetivo y umbrales de alerta. Credenciales de correo y WhatsApp. Despliegue en el ambiente de pruebas de Extreme Technologies contra una réplica de lectura. | Parámetros marcados como validados en `operational_parameter`. Ciclo horario 7 días seguidos sin intervención manual. |
| 1. Piloto consultivo | 4 semanas | CL 72 y SILENCIO, las rutas con mayor diferencia entre lo operado y lo recomendado. Los despachadores usan la pantalla *Hoy* y gestionan alertas agrupadas. La decisión sigue siendo humana; se registra si se siguió la recomendación. | Indicadores de la Sección 7 iguales o mejores que las mismas semanas del año anterior. Alertas descartadas bajo 30 %. |
| 2. Producción | 6–8 semanas | Las tres rutas. Ingreso con las cuentas del operador (SSO), respaldo diario, monitoreo con las herramientas del operador, notificaciones reales por turno, servidor de base separado de la aplicación. | Disponibilidad del ciclo $\geq$ 99 % en un mes; cero incidentes sobre la base operacional. |
| 3. Extensión | continua | Más rutas por grupos. Mejoras del modelo: sentido de la ruta, demanda por segmento, flota compartida entre rutas y planificación del día siguiente. | Cada ruta nueva supera la línea base en su validación temporal antes de activarse. |

- **Identidad.** Hoy el acceso es con claves por rol (lector, operador, administrador). En producción conviene conectar el ingreso al directorio del operador (OpenID Connect) para que la bitácora de alertas, activaciones y parámetros registre personas, no claves.
- **Notificaciones.** Los adaptadores de correo (SMTP con TLS) y WhatsApp Cloud API están implementados. Falta la cuenta institucional, una plantilla aprobada por Meta y la lista de destinatarios por ruta y turno.
- **Sistema de despacho.** La API `/api/v1` ya permite que otro sistema consulte recomendaciones y alertas. Una evolución natural es notificar cambios por *webhook* en lugar de consultar.
- **Observabilidad.** El prototipo expone métricas Prometheus y trazas OpenTelemetry; se conectan a la plataforma que use el operador. Alarmas recomendadas:
  - ciclo fallido o interrumpido;
  - latencia de datos mayor a 2 periodos;
  - deriva o degradación del modelo.

| Componente | Hoy (3 rutas) | Con 50 rutas |
|---|---|---|
| Histórico de demanda | 240.000 franjas en 3 años (unas 27.000 por ruta y año) | Unas 1,3 millones por año: sin cambios para PostgreSQL |
| Observaciones por segmento | 1,18 millones de filas | Crece con viajes × segmentos: particionar por mes (§8.1) al superar unos 10 millones |
| Ingesta | 808.345 registros en 149 s, pico de 964 MB | Procesar por ruta y fecha (RNF-005), en paralelo |
| Entrenamiento completo | 37 min (3 horizontes, 15 intentos de Optuna) en un equipo de desarrollo | Horas: reentrenar sin búsqueda de hiperparámetros (ya lo hace el campeón/retador), más núcleos o modelos por grupo de rutas |
| Ciclo incremental | Un proceso, un ciclo a la vez | Un trabajo por ruta con exclusión por ruta en lugar de global |
| API | Un proceso; consultas paginadas con p95 de 146 ms | Varias réplicas tras un balanceador, con la reanudación de ciclos solo en el programador (`CICLO_REANUDAR=desactivada`) |
| Predicción interactiva | 4,5 s por cálculo | La pantalla *Hoy* lee resultados ya calculados por el ciclo; el cálculo interactivo queda para consultas puntuales |

# 4. Escalabilidad

# 5. Costos

**Licencias: cero.** Todo el sistema usa software libre: PostgreSQL, PostGIS, Python, FastAPI, LightGBM, SonarQube Community, Prometheus y Jaeger. El único costo variable externo es la mensajería de WhatsApp Business, que Meta cobra por conversación; se cotiza según el volumen de alertas críticas. Con los umbrales actuales son unas 13 alertas críticas al día entre las tres rutas, y se reducen al validar la capacidad.

**Infraestructura.**

- **Piloto.** Un servidor de 4 vCPU, 16 GB de RAM y 100 GB de disco con Docker basta. El pico de memoria medido es de 964 MB en la ingesta y la imagen pesa 1,9 GB.
- **Producción.** Dos servidores (aplicación y base de datos), respaldo diario de la base y de `modelos/`, y el monitoreo del operador.

El valor en pesos depende de si se usa infraestructura propia del operador o un proveedor de nube. Se debe cotizar con estas cifras.

**Esfuerzo estimado.**

| Fase | Equipo | Esfuerzo |
|---|---|---|
| 0. Validación | 1 analista + contraparte operativa de SOBUSA | unas 3 personas-semana |
| 1. Piloto | 1 ingeniero + acompañamiento a despachadores | unas 5 personas-semana |
| 2. Producción | 2 ingenieros | unas 14 personas-semana |
| 3. Extensión | 1 ingeniero a medio tiempo | continuo |

**Beneficio por verificar en el piloto.** Al recalcular con la función objetivo las 748 horas-ruta del 1 al 14 de diciembre de 2025, la recomendación usa 608 vehículo-horas menos que lo operado en esas dos semanas, unas 43 por día entre las tres rutas.

- El saldo es neto: CL 72 necesitaría más buses y SILENCIO menos.
- Depende de parámetros todavía sin validar: capacidad, headway máximo y pesos.

El ahorro en pesos es esa cifra por el costo de una vehículo-hora, dato que debe aportar SOBUSA. El piloto existe para confirmarla o corregirla.

## 6. Riesgos y mitigaciones

| **Riesgo** | **Mitigación** |
|---|---|
| Parámetros operativos sin validar | Fase 0. Son parámetros versionados en la base: se corrigen sin desarrollo y queda la versión anterior. |
| Baja adopción por los despachadores | Piloto consultivo; recomendaciones en lenguaje operativo con su razón; pantalla *Hoy*; registro de si se siguió la recomendación. |
| Alertas excesivas | Agrupación por ruta, código y día con gestión en lote; medición del porcentaje de descartadas por regla; recalibración con la capacidad validada. |
| Mala calidad de los datos de sensores | Reglas de calidad CAL-xxx por lote, días sin lecturas tratados como faltantes, ALT-008 y ALT-009. |
| Deriva o degradación del modelo | Monitoreo de deriva, error y cobertura en cada ciclo; reentrenamiento campeón/retador; reversión a la versión anterior en un clic. |
| Carga sobre la base operacional | Réplica de lectura, consultas por rango indexadas, transacciones de solo lectura con timeout, índices solo con aprobación del DBA. |
| Recomendación inviable | Restricciones duras de flota, headway y capacidad; la recomendación se marca *no viable* con el motivo. |
| Caídas y reinicios | Trabajos con latido, reanudación automática y reintentos, verificados con una caída real de la API. |
| Exposición de datos | Mínimo privilegio en las dos bases, sin datos personales de conductores, claves con huella, secretos fuera del repositorio. |
| Dependencia del equipo actual | Manuales técnico, de usuario y de despliegue; 299 pruebas; integración continua con SonarQube; explicación de cada archivo en `comentarios_codigo.pdf`. |
| Compatibilidad de librerías | Versiones fijadas en `requirements.txt`; la instrumentación de trazas sobre SQLAlchemy 2.1 está cubierta por pruebas. |

## 7. Indicadores del piloto

Todos se calculan con datos que el sistema ya guarda:

- espera media estimada (la mitad del headway operado) y ocupación p90 en el tramo más cargado;
- vehículo-horas operadas por día y ruta;
- porcentaje de horas con despachos fallidos (ALT-006);
- error del pronóstico (WAPE) y cobertura del intervalo;
- porcentaje de alertas descartadas;
- porcentaje de horas en que se siguió la recomendación.

## 8. Decisiones que requiere SOBUSA

1. Capacidad por tipología de bus, headway máximo por ruta y franja, y flota disponible por ruta.
2. Valor relativo entre costo de operación, espera de los pasajeros y sobreocupación (pesos de la función objetivo), y costo de una vehículo-hora.
3. Rutas y semanas del piloto, y responsables de operación que lo acompañan.
4. Infraestructura (propia o en la nube), réplica de lectura y directorio para el ingreso.
5. Cuentas de correo y WhatsApp para las notificaciones, y destinatarios por turno.